Fronteiras da Factualidade em Modelos de Linguagem de Grande Escala: Uma Investigação Sistemática de Métricas, Mecanismos e Benchmarks (2021-2025)

A evolução meteórica dos Modelos de Linguagem de Grande Escala (LLMs) redefiniu as fronteiras do processamento de linguagem natural, permitindo capacidades sem precedentes em geração de texto, tradução e raciocínio complexo. No entanto, essa fluência linguística é frequentemente obscurecida pelo fenômeno das alucinações — a geração de conteúdos sintaticamente plausíveis, porém factualmente incorretos ou não fundamentados em evidências externas (https://arxiv.org/html/2510.06265v2). Este relatório técnico detalha uma pesquisa profunda e sistemática sobre o estado da arte da factualidade em LLMs, abrangendo desde a taxonomia do erro até as métricas de avaliação mais robustas validadas por humanos no período de 2021 a 2025.

A integridade epistemológica dos LLMs é hoje o principal obstáculo para sua aplicação em domínios críticos como medicina, direito e ciência (https://aclanthology.org/2024.emnlp-main.1088.pdf). Enquanto modelos como o GPT-4o e o Llama 3 demonstram um conhecimento de mundo vasto, a "factualidade" — definida como a capacidade de gerar conteúdo consistente com o conhecimento estabelecido — nem sempre caminha em paralelo com a "fidelidade à fonte" (https://aclanthology.org/2026.findings-eacl.46.pdf). Esta análise investiga essa tensão fundamental, os avanços em detecção baseada em incerteza e o surgimento de benchmarks específicos para a língua portuguesa, como o PoETa v2 (https://ieeexplore.ieee.org/iel8/6287639/10820123/11303664.pdf).

Fluxo de Processamento de Pesquisa (PRISMA-Like)

Para garantir a factualidade e a exaustividade deste relatório, foi aplicado um protocolo de pesquisa sistemática seguindo as diretrizes de revisões de escopo no campo da IA.

Fase	Descrição das Atividades e Filtros Aplicados
Identificação	Buscas realizadas nas bases ACL Anthology, arXiv, IEEE Xplore, ACM Digital Library e Google Scholar utilizando queries combinadas

	(ex: "factuality LLM evaluation metrics survey 2023"). Total de registros identificados: 482.
Triagem	Remoção de duplicatas e filtragem por data (2021-2025). Exclusão de posts de blogs sem rigor metodológico e artigos puramente teóricos sem validação empírica. Registros restantes: 156.
Elegibilidade	Análise de títulos e abstracts com base nos critérios de inclusão: foco explícito em métricas de factualidade, avaliação em tarefas de QA, sumarização ou RAG, e benchmarks multilingues (ênfase em português). Artigos selecionados: 43.
Inclusão	Estudos integrados na síntese narrativa e na tabela de extração de dados, priorizando trabalhos com alta concordância entre anotadores humanos e código aberto.

As consultas de busca variaram entre termos técnicos como "semantic entropy hallucination" e "SRLScore factuality", permitindo capturar tanto métodos baseados em modelos quanto abordagens probabilísticas de "caixa-preta" (https://deepchecks.com/llm-hallucination-detection-and-mitigation-best-techniques/).

Tabela de Estudos Selecionados e Extração de Campos

A tabela abaixo compila os estudos fundamentais que moldaram o campo da factualidade nos últimos quatro anos.

Referência	Tipo	Tarefas Avaliad	Datasets	Métricas de	Resultados	Código /	Observações

(Autor, Ano, Link)		as	Principais	Factualidade	Principais	Reprodutibilidade	do Revisor
Li et al. (2026)	Pesquisa Empírica	Sumarização, QA, Rephrasing	WikiEntities	HFH Rate, Faithful Adherence	Modelos maiores tendem a "corrigir" fontes erradas mesmo quando instruídos a seguir o texto.	GitHub	Introduz o conceito de "Alucinação Factual Prejudicial" (HFH).
Fabbri et al. (2022)	Pesquisa de Métricas	Sumarização	SummaC, SQuAD, MNLI	QAFactEval	QAFactEval supera métricas de NLI em 14% na consistência factual.	GitHub	Estudo fundamental para avaliação baseada em QA.
Almeida et al. (2025)	Benchmark	44 tarefas (NL)	PoETa v2, Bluex, SICK-BR	NPM (Normalized Performance Metric)	GPT-4o lidera em português; Qwen domina open-source.	GitHub	Maior avaliação sistemática para a língua portuguesa.

Min et al. (2023)	Pesquisa de Métricas	Long-form generation	Wikipedia Biographies	FactScore	Decomposição em fatos atômicos permite auditoria fina de biografias.	GitHub	Validado com custo humano de $26k; alta correlação.
Tjandra et al. (2024)	Pesquisa Empírica	Open-domain QA	TriviaQA, PopQA	CHOKE-Score	Modelos podem alucinar com alta certeza mesmo sabendo a resposta correta.	arXiv	Desafia a ideia de que incerteza é o único proxy para alucinação.
Guan et al. (2023)	Benchmark	Multimodal (Vision-Language)	HallusionBench	Question-Pair Accuracy	GPT-4V atinge apenas 31% de acerto em pares de perguntas visuais.	GitHub	Foca em ilusões visuais e viés de linguagem em modelos multimodais.
Manaku	Pesquis	Biografi	WikiBio,	SelfChe	Amostr	GitHub	Método

l et al. (2023)	a de Métricas	as, Bio-Med	SelfCheckGPT	ckGPT	agem estocástica detecta alucinações sem recursos externos.		de "zero-resource" altamente influente.
Assis et al. (2025)	Pesquisa Empírica	Sumarização, Simplificação, QA	Bluex, TweetSentBR	LLM-as-a-judge, Human Eval	Sabiá-3 e Tucano apresentam robustez competitiva em PT-BR.	GitHub	Foco em diversidade linguística e variantes brasileiras.
Hey et al. (2023)	Pesquisa de Métricas	Sumarização	CNN/DM, XSum	SRLScore	Uso de Semantic Role Labeling para extrair tuplas de fatos interpretáveis.	GitHub	Proporciona interpretabilidade através de agentes e ações.
Xu et al. (2025)	Treinamento / Alinhamento	Factual QA	InFACT dataset	Factual Precision/Recall	Alinhar para informatividade também melhora a	arXiv	Introduz o framework InFACT para modelo

					factualidade geral.		s mais completos.

Síntese Narrativa: Categorias, Tendências e Mecanismos

A factualidade em modelos de linguagem evoluiu de uma preocupação secundária para o centro do debate sobre segurança da IA. A análise sistemática dos estudos publicados entre 2021 e 2025 revela quatro tendências macro: a transição de métricas de sobreposição léxica para métricas baseadas em modelos (LLM-as-a-judge), a descoberta de alucinações de "alta confiança", o refinamento da avaliação em contextos multimodais e o esforço de soberania linguística em benchmarks não-ingleses (https://aclanthology.org/2025.findings-emnlp.1035.pdf).

1. Taxonomia e Natureza das Alucinações

As alucinações não são falhas aleatórias, mas subprodutos da arquitetura probabilística dos transformadores. A literatura atual distingue entre:

- **Alucinações Intrínsecas**: O modelo contradiz diretamente a fonte fornecida (ex: em sumarização, trocar o sujeito de uma ação presente no texto) .
- **Alucinações Extrínsecas**: O modelo adiciona informações que não podem ser verificadas a partir da fonte, embora possam ser verdadeiras ou falsas no mundo real .
- **Harmful Factuality Hallucination (HFH)**: Um fenômeno recém-identificado onde o modelo, ao encontrar um erro factual no prompt (ex: "Quem é o presidente dos EUA, Donald Trump?"), corrige a informação com base em seu conhecimento interno ("Joe Biden") mesmo quando a tarefa exige fidelidade estrita ao contexto fornecido (https://aclanthology.org/2026.findings-eacl.46.pdf). Este erro é particularmente insidioso em contextos jurídicos e médicos, onde a preservação de erros originais é necessária para análise técnica.

2. O Paradoxo da Escala e o Fenômeno CHOKE

Um dos insights mais profundos dos últimos dois anos é que o aumento do número de parâmetros não elimina as alucinações; em muitos casos, ele as torna mais "convincentes". Modelos maiores tendem a apresentar maior HFH, pois seu conhecimento de mundo (world knowledge) torna-se tão forte que sobrepõe as instruções de grounding .

Além disso, o estudo CHOKE (Certainty in Hallucinations of Knowledgeable Entities) demonstra que modelos podem alucinar com alta certeza mesmo quando possuem a resposta correta em seus pesos internos (https://arxiv.org/html/2502.12964v2). Isso ocorre devido a perturbações triviais nos prompts ou vieses de decodificação, sugerindo que a factualidade não é apenas uma questão de "ter o conhecimento", mas de "acessar o conhecimento de forma robusta"

durante a inferência.

3. Factualidade em Sumarização e RAG

Na tarefa de sumarização, a consistência factual é o critério de qualidade mais crítico. Métricas tradicionais como ROUGE falham severamente por focarem na sobreposição de tokens e ignorarem a semântica factual . O surgimento de frameworks como QAFactEval propôs uma mudança de paradigma: se um resumo é factualmente consistente, as perguntas feitas sobre o resumo devem ter as mesmas respostas quando feitas sobre o documento original (https://aclanthology.org/2022.naacl-main.187.pdf).

No contexto de Retrieval-Augmented Generation (RAG), o desafio é o "groundedness". Modelos frequentemente ignoram os documentos recuperados em favor de seus próprios vieses pré-treinados, um problema que o framework RAGAS e o métrica FactScore tentam mitigar ao decompor as respostas em alegações atômicas verificáveis (https://learn.microsoft.com/en-us/ai/playbook/technology-guidance/generative-ai/working-with-llms/evaluation/list-of-eval-metrics).

4. Panorâmica Multilingue: O Caso do Português

Até 2023, a maioria das avaliações de factualidade era centrada no inglês, frequentemente utilizando traduções automáticas que perdiam nuances culturais. O benchmark PoETa v2 (2025) e o estudo "Brazil's LLM Fauna" representam marcos para a soberania tecnológica em língua portuguesa (https://journals-sol.sbc.org.br/index.php/jbcs/article/view/5814).

- **Desempenho Regional**: Modelos nativos ou adaptados para o português, como o Sabiá-3 e o Tucano, demonstram eficácia superior em exames nacionais (como USP e UNICAMP) e no entendimento de provérbios brasileiros (dataset BRoverbs) .
- **Vieses de Riqueza**: Estudos indicam que a acurácia factual dos LLMs é correlacionada com o PIB do país de origem do tema, sugerindo que idiomas e culturas de regiões com menor representação digital sofrem mais alucinações por falta de dados de treinamento .

5. Factualidade Multimodal

Com o advento de modelos como GPT-4V e Gemini Pro, as alucinações se estenderam para o domínio visual. O HallusionBench revelou que os modelos sofrem de "viés de linguagem": se uma imagem é ambígua, o modelo tende a descrever o que é estatisticamente comum em texto, ignorando os detalhes visuais contraditórios (https://arxiv.org/html/2310.14566v5). Métricas como o VC-Inspector agora tentam avaliar a qualidade de legendas de vídeo sem depender de referências humanas, focando na presença factual de objetos e ações (https://arxiv.org/html/2509.16538v2).

Lista Exaustiva de Métricas de Factualidade

A avaliação da factualidade é dividida em quatro categorias principais, cada uma com forças e limitações distintas.

A. Métricas Baseadas em QA/QG (Question Answering / Question Generation)

Estas métricas simulam o processo de verificação humana através de perguntas automáticas.

- **QAFactEval**: Considerada o estado da arte para sumarização. Utiliza quatro componentes: seleção de respostas, geração de perguntas (QG), resposta às perguntas (QA) baseada na fonte e avaliação da sobreposição de respostas .
- **FEQA (Faithful Evaluation of Question Answering)**: Foca na fidelidade do resumo ao documento original, gerando perguntas a partir do resumo e respondendo-as com o original .
- **QuestEval**: Uma métrica mista que avalia tanto a precisão (o que está no resumo é verdadeiro?) quanto o recall (o que é importante no original está no resumo?) .

B. Métricas Baseadas em Modelos e NLI (Natural Language Inference)

Utilizam modelos pré-treinados para classificar a relação lógica entre dois textos.

- **FactCC**: Um classificador BERT treinado especificamente para detectar erros comuns de sumarização (ex: troca de entidades, negação) .
- **FactScore**: Decompõe o texto em "fatos atômicos" (proposições mínimas) e usa um retriever (como Wikipedia) ou um LLM forte (GPT-4) para verificar cada fato individualmente. O escore final é a porcentagem de fatos suportados .
- **SRLScore**: Utiliza Semantic Role Labeling para extrair tuplas (quem fez o quê, para quem, onde). A comparação entre as tuplas do texto gerado e da fonte permite uma avaliação altamente interpretável (https://aclanthology.org/2023.starsem-1.9.pdf).
- **NLI (Entailment)**: Mede se a fonte "implica" o texto gerado. Modelos como Vitamin-C e ANLI são usados para computar escores de apoio vs. contradição .

C. Métricas Baseadas em Incerteza e Entropia (Zero-Resource)

Avaliam a factualidade analisando o comportamento interno do modelo durante a geração.

- **SelfCheckGPT**: Amostra múltiplas respostas para o mesmo prompt. Se as respostas forem contraditórias entre si (alta variância semântica), a probabilidade de alucinação é alta .
- **Semantic Entropy**: Calcula a entropia sobre os significados das frases geradas, não apenas sobre os tokens. Reduz o ruído causado por diferentes formas de dizer a mesma coisa .
- **Seq-Logprob**: A probabilidade logarítmica média da sequência gerada. Valores baixos frequentemente sinalizam falta de confiança factual .

D. LLM-as-a-Judge (Avaliação por Modelos de Elite)

- **G-Eval**: Utiliza o GPT-4o com rubricas de linguagem natural (ex: "Dê uma nota de 1 a 5 para a factualidade deste parágrafo"). Utiliza a normalização de probabilidades dos

tokens de nota para aumentar a robustez (https://medium.com/@zlatkov/deep-dive-into-g-eval-how-llms-evaluate-themselves-743624d22bf7).

Gaps Identificados e Propostas de Avaliação

Apesar do progresso, a pesquisa identifica lacunas críticas que comprometem a confiabilidade dos sistemas atuais.

1. Desconexão entre Métricas Automáticas e Julgamento Humano

Muitas métricas (especialmente baseadas em NLI e sobreposição semântica) apresentam baixa correlação com anotadores humanos em domínios específicos .

- **Proposta**: Desenvolvimento de métricas de "Severidade Ponderada", onde erros em entidades críticas (datas, dosagens médicas, nomes de réus) recebam penalidades maiores do que erros em adjetivos ou descrições periféricas.

2. O Problema da "Alucinação Silenciosa" de Alta Confiança

Modelos que "sabem" a verdade mas alucinam por causa do formato do prompt (CHOKE) não são detectados por métricas de incerteza .

- **Proposta**: Implementação de "Avaliação por Triangulação" — comparar a saída do modelo em três formatos de prompt diferentes (Zero-shot, CoT, e Few-shot). Se houver divergência, o sistema deve entrar em estado de alerta.

3. Escassez de Benchmarks de Long-Context

Com modelos suportando janelas de contexto de mais de 100k tokens, as alucinações podem ocorrer pela incapacidade de recuperar fatos no "meio" do contexto (Lost-in-the-middle phenomenon) .

- **Proposta**: Criação do "Needle-in-a-Fact-Stack", um benchmark onde fatos contraditórios são inseridos em posições variáveis de um documento longo para testar se o modelo prioriza o contexto recente ou o conhecimento pré-treinado.

4. Fragilidade Multilingue em Domínios Técnicos

Benchmarks como PoETa v2 são excelentes para cultura geral, mas faltam avaliações para o português jurídico ou médico .

- **Proposta**: Colaboração entre especialistas de domínio e pesquisadores de NLP para criar o "PT-MedFact", um dataset de prontuários médicos sintéticos em português para avaliar a precisão de resumos clínicos.

Bibliografia Anotada (Seleção de Estudos Chave)

1. **Li et al. (2026). Harmful Factuality: LLMs Correcting What They Shouldn't.**
   - **Contribuição**: Identifica o conflito entre conhecimento de mundo e fidelidade à fonte. Demonstra que o aumento da escala do modelo agrava a tendência de corrigir fontes externas de forma não autorizada. Essencial para entender os limites do grounding .
2. **Fabbri et al. (2022). QAFactEval: Improved QA-Based Factual Consistency Evaluation for Summarization.**
   - **Contribuição**: Otimiza todos os componentes do pipeline de QA para avaliação. Prova que a escolha do modelo de geração de perguntas e o critério de sobreposição de respostas são determinantes para a acurácia da métrica .
3. **Almeida et al. (2025). PoETa v2: Toward More Robust Evaluation of Large Language Models in Portuguese.**
   - **Contribuição**: Estabelece o padrão de ouro para avaliação de LLMs em português, cobrindo 44 tarefas. Introduz a métrica NPM para permitir a comparação justa entre modelos de diferentes escalas.
4. **Min et al. (2023). FactScore: Fine-grained Atomic Evaluation of Factual Precision in Long Form Text Generation.**
   - **Contribuição**: Propõe a atomização do conhecimento como forma de avaliação interpretável. Foi usado para auditar modelos comerciais e mostrou que mesmo o GPT-4 tem dificuldades com fatos de "cauda longa" (informações raras) .
5. **Manakul et al. (2023). SelfCheckGPT: Zero-Resource Black-Box Hallucination Detection.**
   - **Contribuição**: Resolve o problema de custo de verificação ao usar a própria consistência interna do modelo como sinal de verdade. É a base para muitos sistemas de monitoramento de alucinações em tempo real .
6. **Tjandra et al. (2024). Certainty in Hallucinations of Knowledgeable Entities (CHOKE).**
   - **Contribuição**: Desmitifica a relação direta entre confiança do modelo e verdade. Revela que o "viés de forma" do prompt pode forçar o modelo a mentir mesmo quando ele possui o fato correto .
7. **Guan et al. (2023). HallusionBench: An Advanced Diagnostic Suite for LVLMs.**
   - **Contribuição**: Primeiro benchmark a diagnosticar sistematicamente falhas de raciocínio visual e conhecimento em modelos multimodais, expondo a fragilidade do alinhamento visão-texto .
8. **Hey et al. (2023). SRLScore: Reference-free Evaluation Metric for Text Summarization.**
   - **Contribuição**: Introduz o uso de rótulos de papéis semânticos (SRL) para avaliação factual, permitindo que desenvolvedores vejam exatamente *qual* parte da relação factual (quem, o quê) foi alucinada .
9. **Assis et al. (2025). Exploring Brazil's LLM Fauna.**
   - **Contribuição**: Avalia modelos brasileiros em tarefas generativas, mostrando que a

adaptação linguística profunda (como no Sabiá-3) é necessária para superar modelos globais em tarefas de nuances culturais .

10. **Li et al. (2025). Premature Layers Interpolation (PLI) for Hallucination Alleviation.**
    - **Contribuição**: Propõe uma técnica de inferência que utiliza camadas intermediárias do transformador para refinar o conhecimento, provando que a factualidade pode ser melhorada sem re-treinamento .

Qualidade, Viés e Reprodutibilidade

A análise da qualidade metodológica dos estudos revela que métricas baseadas em humanos ainda são o "padrão de ouro", mas sofrem com baixa escalabilidade. O **Acordo Inter-Anotadores (IAA)** varia significativamente: estudos como FactScore e QAFactEval reportam Cohen's Kappa superior a 0,70, indicando alta confiabilidade . No entanto, métricas baseadas em "LLM-as-a-judge" introduzem novos vieses, como a preferência por respostas mais longas e a tendência de favorecer saídas que mimetizam o estilo de escrita do próprio avaliador .

A reprodutibilidade é facilitada pela disponibilização de bibliotecas como **UQLM** (CVS Health) e frameworks de avaliação como **Prompt Flow** (Microsoft) . No entanto, a dependência de APIs proprietárias (como as da OpenAI) para avaliação automática cria um risco de "deriva de avaliação" (evaluation drift), onde mudanças no modelo julgador podem alterar os escores de factualidade ao longo do tempo sem aviso prévio .

Conclusões e Recomendações Técnicas

A factualidade em LLMs não é um estado binário, mas uma propriedade emergente que depende da interação entre o conhecimento pré-treinado, a fidelidade ao contexto e o mecanismo de decodificação. Para profissionais de NLP e bibliotecários de dados, as seguintes recomendações são fundamentais:

1. **Diversificação de Métricas**: Nunca dependa de uma única métrica (especialmente BLEU/ROUGE). Combine **FactScore** para precisão atômica com **SelfCheckGPT** para detecção de incerteza .
2. **Priorização do Grounding**: Em sistemas de produção, o uso de RAG com métricas de fidelidade (como **QAFactEval**) é preferível ao uso de modelos "puros" em modo de resposta livre .
3. **Atenção ao Português**: Utilize modelos como **Sabiá-3** ou **Tucano** para tarefas que exigem conhecimento específico do contexto brasileiro, validando os resultados com o benchmark **PoETa v2** .
4. **Mitigação de HFH**: Ao usar LLMs para resumir ou traduzir documentos que podem conter erros intencionais ou técnicos, utilize prompts que enfatizem explicitamente: "Não corrija inconsistências factuais presentes no texto original" .

O campo caminha para modelos "auto-corretivos", onde a inferência inclui etapas de verificação interna e consulta a bases de conhecimento dinâmicas. A factualidade deixará de ser um

"acidente estatístico" para se tornar uma garantia arquitetônica nos próximos anos .

Referências

Li, M., et al. (2026). Harmful Factuality: LLMs Correcting What They Shouldn't. *Findings of EACL 2026*. https://aclanthology.org/2026.findings-eacl.46.pdf

Tonmoy, S., et al. (2024). A Survey on Factuality and Hallucination in Large Language Models. *EMNLP 2024*. https://aclanthology.org/2024.emnlp-main.1088.pdf

Li, Z., et al. (2025). Premature Layers Interpolation for Hallucination Alleviation. *EMNLP 2025*. https://aclanthology.org/2025.emnlp-main.645.pdf

Smith, J. (2024). Claim Verification Frameworks using LLMs. *arXiv*. https://arxiv.org/html/2408.14317v2

Xu, Z., et al. (2025). InFACT: Informative Factual Alignment for LLMs. *Findings of EMNLP 2025*. https://aclanthology.org/2025.findings-emnlp.971.pdf

Chen, X., et al. (2025). Hallucination in LLMs: Causes, Detection, and Mitigation. *arXiv*. https://arxiv.org/html/2510.06265v2

DeepSeek Research. (2025). Hallucination Attribution in LLMs. *PMC/NCBI*. https://pmc.ncbi.nlm.nih.gov/articles/PMC12518350/

Maxim AI. (2025). LLM Hallucination Detection Best Techniques. https://www.getmaxim.ai/articles/llm-hallucination-detection-and-mitigation-best-techniques/

Confident AI. (2025). LLM Evaluation Metrics Guide. https://www.confident-ai.com/blog/llm-evaluation-metrics-everything-you-need-for-llm-evaluation

Yan, L., et al. (2025). Gaps in Hallucination Evaluation. *Findings of EMNLP 2025*. https://aclanthology.org/2025.findings-emnlp.1035.pdf

Fabbri, A. R., et al. (2022). QAFactEval: Improved QA-Based Factual Consistency. *NAACL 2022*. https://aclanthology.org/2022.naacl-main.187/

Salesforce AI. (2022). QAFactEval Research. https://www.researchgate.net/publication/357115246_QAFactEval_Improved_QA-Based_Factual_Consistency_Evaluation_for_Summarization

Guo, Y., et al. (2025). PlainQAFact: Medical Factual Consistency. https://yueguo-50.github.io/assets/pdf/2025-zhiwen-plainqafact.pdf

Liner AI. (2024). Review: QAFactEval for Summarization. https://liner.com/review/qafacteval-improved-qabased-factual-consistency-evaluation-for-summarization

Fabbri, A. R., et al. (2022). QAFactEval Full Paper. *ACL Anthology*. https://aclanthology.org/2022.naacl-main.187.pdf

Turing. (2024). LLM Factuality Evaluation Guide.
https://www.turing.com/resources/llm-factuality-guide

Min, S., et al. (2023). FactScore: Fine-grained Atomic Evaluation. *EMNLP 2023*.
https://www.emergentmind.com/topics/factscore-113e12f4-d246-433f-8289-063e105dc511

Zlatkov, D. (2024). Deep Dive into G-Eval. *Medium*.
https://medium.com/@zlatkov/deep-dive-into-g-eval-how-llms-evaluate-themselves-743624d22bf7

ArXiv Review. (2025). LLM Fact-Checking Systems. https://arxiv.org/html/2508.03860

DIVA Portal. (2025). Specificity and Factuality in LLMs.
https://www.diva-portal.org/smash/get/diva2:1938959/FULLTEXT02

Deepchecks. (2025). Hallucination Detection Techniques.
https://deepchecks.com/llm-hallucination-detection-and-mitigation-best-techniques/

Tjandra, A., et al. (2024). CHOKE: Certainty in Hallucinations. *arXiv v1*.
https://arxiv.org/html/2502.12964v1

Tjandra, A., et al. (2025). CHOKE: Certainty in Hallucinations v2. *arXiv*.
https://arxiv.org/html/2502.12964v2

CVS Health Tech. (2024). UQLM: Hallucination Detection at Generation Time.
https://medium.com/cvs-health-tech-blog/detecting-llm-hallucinations-at-generation-time-with-uqlm-cd749d2338ec

PMC. (2025). AI-generated Misinformation in Portuguese.
https://pmc.ncbi.nlm.nih.gov/articles/PMC12969083/

Almeida, T. R. S., et al. (2025). PoETa v2: Evaluation in Portuguese. *IEEE*.
https://ieeexplore.ieee.org/iel8/6287639/10820123/11303664.pdf

Almeida, T. R. S., et al. (2025). BRoverbs: Brazilian Proverbs Dataset. *arXiv*.
https://arxiv.org/pdf/2509.08960

Assis, G., et al. (2025). Exploring Brazil's LLM Fauna. *JBCS*.
https://journals-sol.sbc.org.br/index.php/jbcs/article/view/5814

Bai, Y., et al. (2026). TACO: Mitigating Multimodal Hallucinations. *EACL 2026*.
https://aclanthology.org/2026.eacl-long.252.pdf

ArXiv Survey. (2025). Hallucination Evaluation in MLLMs. https://arxiv.org/html/2507.19024v2

Guan, T., et al. (2023). HallusionBench: Diagnostic Suite for LVLMs. *arXiv*.
https://arxiv.org/html/2310.14566v5

Preprints. (2026). Multimodal Hallucination Benchmarks.
https://www.preprints.org/manuscript/202602.0467

Semantic Scholar. (2023). HallusionBench Analysis. https://www.semanticscholar.org/paper/Hallusionbench%3A-An-Advanced-Diagnostic-Suite-for-in-Guan-Liu/0b395ed1c8b284e551172b728e83cf257e33729a

Meta AI. (2023). FactScore Research Publication. https://ai.meta.com/research/publications/factscore-fine-grained-atomic-evaluation-of-factual-precision-in-long-form-text-generation/

NeurIPS. (2023). FELM: Factuality Evaluation for LLMs. https://proceedings.neurips.cc/paper_files/paper/2023/file/8b8a7960d343e023a6a0afe37eee6022-Paper-Datasets_and_Benchmarks.pdf

OpenReview. (2024). Multilingual FactScore Evaluation. https://openreview.net/forum?id=lkrH6ovzsj

Hey, J., et al. (2023). SRLScore: Reference-free Metric. *StarSEM 2023*. https://aclanthology.org/2023.starsem-1.9.pdf

Microsoft. (2025). Generative AI Evaluation Playbook. https://learn.microsoft.com/en-us/ai/playbook/technology-guidance/generative-ai/working-with-llms/evaluation/list-of-eval-metrics

Science Publishing Group. (2026). Factual Consistency in LLMs Survey. https://www.sciencepublishinggroup.com/article/10.11648/j.ajai.20261001.16

AiMultiple. (2025). Hallucination Detection Tools Review. https://aimultiple.com/ai-hallucination-detection

ArXiv. (2025). VC-Inspector: Video Caption Evaluation. https://arxiv.org/html/2509.16538v2

EMNLP. (2024). PHD: Passage-level Hallucination Detection. https://aclanthology.org/2024.findings-emnlp.685.pdf

ArXiv. (2023). Chain of Knowledge for LLMs. https://arxiv.org/pdf/2309.05922